

少样本细胞核图像 5 分类

强方案执行手册

面向 5 类、每类 50 张、 32×32 RGB 细胞核图像的现场跑分系统



Class_0 示例 1 (原图 32×32)



Class_0 示例 2 (原图 32×32)

说明： 32×32 图像经最近邻放大，仅用于展示；训练/推理建议用

版本：v1.0 日期：2026-05-21 计算资源：RTX Pro 6000 + RTX 5090

核心结论：用多个公开预训练视觉 backbone 提取强特征，再通过 linear probe、prototype/kNN/cache、少量 LoRA/Adapter、TTA 和 OOF 融合组合使用；不要押宝从零训练的小 CNN。

一句话策略

最终系统应当是“多 backbone frozen embedding + 支持集检索式 few-shot + 轻量线性分类器 + 保守 TTA + OOF 学融合权重”。LoRA、prompt、RAG、伪标签都作为增益分支，而不是主干。

目录

1. 1. 作业目标、约束与评分指标
2. 2. 总体系统架构与优先级
3. 3. 数据检查、交叉验证与防泄漏
4. 4. 32×32 细胞核图像的预处理与增强
5. 5. 多 backbone 特征库：通用、医学、CLIP 与传统特征
6. 6. 轻量分类头：linear probe、SVM、Ridge、kNN、prototype、cache
7. 7. LoRA/Adapter 微调方案
8. 8. CLIP prompt、Tip-Adapter 与 RAG 的正确用法
9. 9. TTA、伪标签、label propagation 与现场 test-time adaptation
10. 10. OOF 融合、校准、类别偏置与模型选择
11. 11. 双 GPU 现场运行流程与离线准备
12. 12. 代码结构、命令行与关键伪代码
13. 13. 实验报告写法、消融表格与误差分析
14. 14. 风险控制、最终清单与执行顺序
15. 附录 A. 超参数搜索表
16. 附录 B. 参考资料与许可证记录模板

1. 作业目标、约束与评分指标

课程任务是少样本 5 分类。训练集位于 train_few_shot/, 类别为 Class_0 至 Class_4, 每类 50 张, 共 250 张; 图像尺寸为 32×32 RGB。现场提供大规模且类别不平衡的测试集, 最终提交 submission.csv, 格式为 filename,label。评分指标是 macro-F1 与 balanced accuracy。[C0]

关键约束

允许公开预训练权重和开源工具链; 禁止把任何外部带标签图像数据集作为训练或验证数据。允许做数据增强、自监督、伪标签, 但必须避免引入外部人工标签或外部验证集。使用预训练模型时, 报告必须说明来源、许可证、参数量和推理成本。

1.1 为什么不能只看普通 accuracy

测试集不平衡时, 普通 accuracy 可能被大类样本撑高。例如测试集中 Class_0 很多, 模型只要偏向 Class_0 就可能得到较高普通 accuracy, 但小类召回率会非常差。课程强调 balanced accuracy 和 macro-F1, 因此每个类别都必须被公平对待。

指标	定义	对本题的含义	优化风险
Balanced accuracy	各类别 recall 的平均值。[R1]	每个类别召回率同等重要; 小类漏检会直接拉低分数。	不能只追求整体正确率; 不能把预测分布压向测试大类。
Macro-F1	先分别计算每类 F1, 再不加权平均。F1 是 precision 与 recall 的调和平均。[R2]	既看每类召回, 也看每类预测精度; 乱报某类会损害 precision。	不能简单提高某类 bias 来刷 recall, 否则 precision 会掉。
内部选择目标	$\text{score} = 0.5 * \text{macro-F1} + 0.5 * \text{balanced accuracy}$	用于统一比较模型和融合权重。	必须只在 OOF 验证预测上调参。

1.2 作业成功标准

- 现场测试时能在无网络、有限时间下稳定运行, 自动输出格式正确的 submission.csv。
- 内部交叉验证上 macro-F1 与 balanced accuracy 同时高, 而不是只靠某次随机划分。
- 模型组合有清晰动机: 通用视觉特征、医学/显微域特征、CLIP few-shot、传统纹理特征互补。
- 实验报告能解释为什么选择这套方案, 并给出消融、失败尝试、误差分析和模型许可证记录。

2. 总体系统架构与优先级

少样本细胞核 5 分类：最终推荐系统结构




图 1. 推荐的最终系统结构。每个分支都能独立运行, 现场某个模型失败时可以自动跳过。

2.1 主战术

主战术不是“从零训练一个小 ResNet”，也不是“只用一个大模型端到端微调”，而是把 250 张训练图当作 support set，站在多个 foundation model 的 embedding 空间上做少样本分类。

层级	组件	作用	是否必做
第 1 层	DINOv2/DINOv3/ConvNeXt/EVA 等通用视觉 backbone	提供跨域强视觉表征；通常 frozen feature + 线性头即可很强。	必做
第 2 层	Phikon-v2/BioMedCLIP/Cell-DINO 等医学或细胞分支	利用显微、组织学、细胞形态的预训练先验。	强烈建议
第 3 层	OpenCLIP/SigLIP/BioMedCLIP 的 prompt + support cache	满足 zero-shot/few-shot 方向，同时避免 Class_X 无语义的问题。	建议
第 4 层	HOG/LBP/颜色统计 + SVM	给出传统纹理 baseline；在 32×32 小图上有时很稳。	建议低权重融合
第 5 层	LoRA/Adapter	只对 CV 上最强的 2-3 个 backbone 做参数高效微调，尝试提高上限。	有时间再做
第 6 层	label propagation / 高置信伪标签	现场拿到无标签测试集后，可在规则允许时做轻量转导适配。	做成开关

2.2 实验优先级

优先级	实验	预期收益	停止条件
1	DINOv2-L/G frozen feature + LogisticRegression + kNN/cache	最稳、最快建立强 baseline。	OOF 明显高于传统特征后继续扩展。
2	DINOv3 ViT/ConvNeXt 分支	更新的通用视觉特征，和 DINOv2 互补。	若加载/许可证/环境不稳，现场 fast 模式跳过。
3	Phikon-v2、BioMedCLIP、Cell-DINO	利用显微和病理域先验。	若某分支 OOF 低但错误互补，可保留低权重。
4	D4 TTA + RGB/Gray3/Contrast 多输入版本	增强旋转、翻转和染色鲁棒性。	若耗时过大，现场 fast 模式只用 identity + D4。
5	OOF 融合权重、温度缩放、class bias	直接针对 macro-F1/bAcc 优化。	融合权重只基于 OOF，不看测试标签。
6	LoRA/Adapter	提高上限，但有过拟合风险。	若 CV 方差大或 OOF 不升，降低权重。
7	伪标签/label propagation	现场无标签测试集很大时可能增益。	老师禁止 test-time training 时关闭。

3. 数据检查、交叉验证与防泄漏

3.1 EDA 必做项

- 检查每张图是否都是 32×32 RGB；如果有灰度图、RGBA 或尺寸异常，统一 convert("RGB") 并记录。
- 统计每类数量是否均为 50；训练集文件名、类别目录是否干净。
- 每类画 50 张 montage：观察大小、形状、边界清晰度、紫色染色深浅、背景噪声、内部颗粒度。
- 检查重复图和近重复图：计算像素 hash、感知 hash、embedding 余弦相似度；近重复样本不要跨 fold 泄漏。
- 保存 EDA 图到 reports/eda/，报告中至少放每类样本网格和最相似/最难样本示例。

```
# scripts/eda.py: 最小检查清单
from pathlib import Path
from PIL import Image
from collections import Counter
```

```
root = Path('final-project/train_few_shot')
classes = sorted([p.name for p in root.iterdir() if p.is_dir()])
counts = Counter()
for c in classes:
    for p in (root / c).glob('*.png'):
        img = Image.open(p)
```

```

assert img.size == (32, 32), (p, img.size)
assert img.mode in ['RGB', 'RGBA', 'L'], (p, img.mode)
counts[c] += 1
print(classes, counts)
assert classes == [f'Class_{i}' for i in range(5)]
assert all(counts[f'Class_{i}'] == 50 for i in range(5))

```

3.2 交叉验证设计

250 张训练图太少，任何单次 train/val split 都可能高估或低估模型。因此推荐 RepeatedStratifiedKFold: 5 折，每折每类约 40 张训练、10 张验证；重复 5-10 次估计方差。所有模型必须用同一套 fold，方便融合权重学习。

- 基础阶段：RepeatedStratifiedKFold(n_splits=5, n_repeats=5, random_state=42)。
- 最终阶段：n_repeats=10，得到更稳定 OOF 概率。
- 模型选择和融合权重只用 OOF 预测，不用测试集标签，也不要反复手动调到某个 fold。
- 输出每类 precision/recall/F1、balanced accuracy、confusion matrix 和低置信样本。

```

from sklearn.model_selection import RepeatedStratifiedKFold
from sklearn.metrics import f1_score, balanced_accuracy_score

rkf = RepeatedStratifiedKFold(n_splits=5, n_repeats=5, random_state=42)
for fold, (tr, va) in enumerate(rkf.split(X, y)):
    clf.fit(X[tr], y[tr])
    prob = clf.predict_proba(X[va])
    pred = prob.argmax(1)
    macro_f1 = f1_score(y[va], pred, average='macro')
    bacc = balanced_accuracy_score(y[va], pred)
    print(fold, macro_f1, bacc)

```

3.3 防泄漏原则

- 不要把同一张图的增强版本分到 train 和 val 两边；增强只在训练 fold 内生成。
- 如果做 feature 标准化、PCA、温度缩放、class bias、融合权重，必须只用当前训练 fold 或 OOF 预测拟合。
- 伪标签只能在最后作为可选现场流程；不能把测试图的伪标签拿来调验证指标。
- 任何手工观察测试集图像都不要转换成类别规则；可以做无标签统计和异常图检查。

4. 32×32 细胞核图像的预处理与增强

细胞核图像尺寸极小，类别差异很可能来自形态、边界、纹理、模糊程度、染色深浅和背景。预处理目标是保留这些信息，而不是套用 ImageNet 分类常用的大尺度裁剪。

4.1 输入版本

输入版本	具体做法	目的	建议
Raw RGB	32×32 直接用 bicubic 或 Lanczos 上采样到模型输入尺寸。	保留原始颜色、染色和纹理。	所有 backbone 必做。
Gray3	转灰度后复制 3 通道，再使用模型对应 normalization。	降低染色变化影响，突出形态和边界。	适合 DINO/ConvNeXt/传统特征。
Contrast/CLAHE	轻微局部对比度增强，不改变几何结构。	突出核边界和内部颗粒。	作为额外分支，低权重融合。
Light denoise/sharpness	极轻微去噪或锐化。	增强低对比图像。	只在 OOF 有收益时保留。

4.2 Resize 和 normalization

- 上采样优先 bicubic 或 Lanczos；展示图可以最近邻放大，但训练/推理不要最近邻。
- 每个模型使用自己的 preprocessing: timm 用 resolve_model_data_config/create_transform；HuggingFace 模型使用 AutoImageProcessor；OpenCLIP 使用 create_model_and_transforms 返回的 preprocess_val。
- 不要手动把所有模型都统一成一个 normalize；不同预训练模型的 mean/std 和输入尺寸可能不同。
- DINOv3 官方示例对 LVD-1689M 权重使用 ImageNet evaluation transform，即 resize 后用 ImageNet mean/std。[R5]

4.3 训练增强

增强	推荐强度	原因
HorizontalFlip / VerticalFlip	p=0.5	显微图像通常没有固定方向语义。
Rotate 90/180/270	随机或 D4 采样	增强方向不变性。
Brightness/Contrast/Saturation	幅度 0.05-0.15	模拟轻微染色与曝光变化。
Gaussian noise / blur	非常轻	提高对模糊和噪声的鲁棒性。
Random crop	不建议，最多 padding 后微平移	32×32 主体很小，裁剪可能破坏标签。
MixUp/CutMix	谨慎；alpha <= 0.2 或仅做实验	小核图像混合后语义容易不清。
RandAugment	低强度；只作为消融	强颜色/几何变换可能破坏细胞核形态。

增强原则

保守增强优先。任何增强策略都必须在 OOF 上证明有效；如果只提升训练集而降低验证集，立即删除。

5. 多 backbone 特征库：通用、医学、CLIP 与传统特征

本题最重要的工程动作是建立“特征库”：对每个训练/测试图像，用多个公开预训练模型提取 embedding，保存为 .npy。后续所有分类头、融合、检索和伪标签都基于这些 embedding，现场不必重复训练大模型。

5.1 通用视觉 backbone

Backbone	推荐用途	依据与注意事项
DINOv2 ViT-L/G with registers	主力 frozen feature；LogReg、kNN、cache 都做。	DINOv2 官方说明其视觉特征可直接配合线性分类器，并且预训练未使用标签。[R3] ViT-S/B/L/G 参数量约 21M/86M/300M/1100M。[R12]
DINOv3 ViT-L/H 或 ConvNeXt-L	更新主力分支；用 pooled_output 或 CLS/patch 平均特征。	DINOv3 提供 ViT 与 ConvNeXt 系列，并支持用 Transformers 做 image-feature-extraction。[R4][R5]
ConvNeXtV2 / EfficientNet / EVA	补充 CNN inductive bias 与不同预训练空间。	通过 timm 统一提取 pre-classifier feature；timm 文档说明可一致获取分类头前特征。[R6]
EVA-CLIP / SigLIP / OpenCLIP	作为 CLIP 类图像编码器；不要只靠文本 zero-shot。	OpenCLIP 提供多种 LAION/DataComp 预训练模型。[R10]

5.2 医学、病理与细胞分支

Backbone	为什么适合	报告需要记录
Phikon-v2	ViT-L/16，经 DINOv2 自监督方法在大规模 histology 图像上预训练；模型卡明确建议 CLS token 用于 linear 或 kNN probing。[R7]	Owkin non-commercial license；约 0.3B 参数；输入多为 224×224 histology patch。
BioMedCLIP	生物医学视觉-语言模型，PMC-15M 图文对预训练，覆盖 microscopy、histology 等图像类型。[R8]	MIT license；使用 OpenCLIP 加载；建议 image encoder + support cache，而不是只 prompt。
Cell-DINO	面向 cellular morphology / microscopy 的 DINOv2 风格自监督表征；论文指出可把细胞图像转成定量 phenotypic embedding。[R9]	若你的图像更接近 H&E 紫色核图，效果需 OOF 验证；作为互补分支。
UNI/CONCH（可选）	强 histopathology foundation model；如果图像接近 H&E 病理切片可试。	通常需要 HuggingFace 注册/条款同意；CC-BY-NC-ND 或类似非商业限制，现场前必须缓存。

5.3 传统特征分支

HOG、LBP、颜色直方图、灰度统计、边缘强度等传统特征在 32×32 小图上并不一定弱。它们作为低权重分支有两个价值：第一，提供不同于 foundation model 的纹理/颜色归纳偏置；第二，在报告中形成可解释 baseline。

特征	建议参数	分类器
HOG	orientations=8 或 9； pixels_per_cell=(4,4)；	LinearSVC / LogisticRegression

	cells_per_block=(2,2)	
LBP	P=8, R=1 或 multi-radius; 每通道或灰度图	SVM / RandomForest / kNN
颜色统计	RGB/HSV 均值、方差、分位数; 颜色直方图	Ridge / LogisticRegression
形态/边缘	Sobel/Canny 边缘比例、中心亮度、对比度	与 HOG/LBP 拼接

6. 轻量分类头：linear probe、SVM、Ridge、kNN、prototype、cache

冻结 backbone 后，训练的是轻量分类器。这样能显著降低过拟合风险，也便于做 OOF 概率、融合和现场快速重训。

6.1 Linear probe

分类头	超参数	优点	注意
LogisticRegression	C=[0.01,0.03,0.1,0.3,1,3,10,30,100]; max_iter=5000; class_weight 可比较	有 predict_proba, 适合融合和伪标签。	必须 StandardScaler; C 过大可能过拟合。
RidgeClassifier	alpha=[0.1,0.3,1,3,10,30,100]	对小样本稳定; 可用 decision_function 转概率。	概率需校准。
LinearSVC	C=[0.01,0.03,0.1,0.3,1,3,10]	高维 embedding 上常很强。	概率需要 CalibratedClassifierCV 或 softmax decision。
MLP head	1 hidden layer, dropout>=0.3, weight decay	可拟合非线性。	250 张样本极易过拟合, 只作为消融。

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
```

```
clf = make_pipeline(
    StandardScaler(),
    LogisticRegression(
        C=1.0,
        solver='lbfgs',
        max_iter=5000,
        class_weight='balanced'
    )
)
clf.fit(X_train, y_train)
prob = clf.predict_proba(X_val)
```

6.2 Prototype / kNN / cache classifier

少样本任务中，训练集每张图都是 support image。不要只训练一个线性头；还应把训练集 embedding 当成检索库。

- Nearest centroid: 每类 embedding 取均值，测试图与 5 个类中心做 cosine similarity。
- kNN: 测试图检索训练集中最相近 k 张，按距离加权投票。k 建议 [1,3,5,7,11,15]。
- Cache classifier: 把训练 embedding 作为 keys，one-hot 标签作为 values，用 $\exp(\beta * \text{cosine})$ 聚合得到 logits。
- Tip-Adapter 思路: CLIP few-shot 中用 key-value cache 模型通过特征检索修正 zero-shot 先验。[R11] 本题可以把这个思想推广到 DINO/Phikon/BioMedCLIP 等任意 encoder。

```
import numpy as np
```

```
def cache_logits(z_test, z_train, y_train, beta=20.0, topk=None, num_classes=5):
    # z_* 已经 L2 normalize. z_test: [n,d], z_train: [250,d]
    sim = z_test @ z_train.T
    if topk is not None:
        idx = np.argpartition(-sim, kth=topk-1, axis=1)[: , :topk]
        logits = np.zeros((z_test.shape[0], num_classes), dtype=np.float32)
        for i in range(z_test.shape[0]):
            s = sim[i, idx[i]]
            w = np.exp(beta * s)
```



```

        for jj, weight in zip(idx[i], w):
            logits[i, y_train[jj]] += weight
    return logits
weights = np.exp(beta * sim)
Y = np.eye(num_classes)[y_train]
return weights @ Y

```

6.3 分类头组合建议

每个 backbone 都应输出	保存文件	用于融合
LogisticRegression 概率	oof_probs/{model}_logreg.npy, test_probs/{model}_logreg.npy	主概率
Ridge/LinearSVC decision 转概率	oof_probs/{model}_ridge.npy	互补概率
kNN/prototype/cache logits	oof_probs/{model}_cache.npy	few-shot 检索分支
embedding 本身	features/{split}_{model} _{input_variant}.npy	伪标签、检索、误差分析

7. LoRA/Adapter 微调方案

你有 RTX Pro 6000 和 RTX 5090，算力足够做 LoRA/Adapter，但数据只有 250 张，因此原则是“少量参数、强正则、交叉验证、低权重融合”。LoRA 通过低秩分解减少需要训练的参数，PEFT 文档也强调其能降低显存和训练成本。[R13]

7.1 微调对象选择

- 只对 OOF 表现最强的 2-3 个 backbone 做 LoRA，例如 DINOv2-L/DINOv3-L、Phikon-v2、BioMedCLIP image encoder。
- 不要全量 fine-tune 300M/1B 模型；250 张图会迅速记忆训练集。
- LoRA 分支如果 OOF 只提升极小且方差大，最终融合权重应低。
- 每个 fold 训练独立 LoRA checkpoint；现场可用 5-fold checkpoint ensemble 或 all-data checkpoint。

项目	推荐设置
LoRA rank r	4、8、16 三档搜索；先从 r=8 开始。
alpha	8、16、32；通常 alpha/r 在 1-4 之间。
target modules	ViT 通常 q_proj/v_proj 或 qkv/proj；具体名称用 print(model.named_modules()) 确认。
learning rate	head: 1e-3；LoRA: 1e-5 到 1e-4；可用不同 param group。
epochs	30-100；patience 10；保存 best OOF。
loss	CrossEntropy + label_smoothing=0.03-0.10；可加 class weight。
batch size	32-128；根据输入尺寸和模型调。
增强	D4 + 轻 color jitter + 轻噪声；不要强 crop。
正则	weight_decay=0.01-0.05；dropout=0.1-0.3；EMA 可试。

```

# LoRA 伪代码：模型模块名需按实际 backbone 调整
from peft import LoraConfig, get_peft_model

lora_cfg = LoraConfig(
    r=8,
    lora_alpha=16,
    target_modules=['q_proj', 'v_proj'], # 或 ['qkv', 'proj']，以实际模块名为准
    lora_dropout=0.05,
    bias='none'
)
model = get_peft_model(model, lora_cfg)
# 只训练 LoRA 和分类头；backbone 其他参数冻结

```

LoRA 判断准则

只有当 LoRA 分支在 repeated OOF 上稳定提升 macro-F1 和 balanced accuracy，且混淆矩阵显示其纠正了 frozen feature 的错误时，才在最终融合中给高权重。

8. CLIP prompt、Tip-Adapter 与 RAG 的正确用法

8.1 纯 zero-shot 的风险

CLIP 通过图像与文本匹配做 zero-shot 分类，OpenAI CLIP 官方说明它可根据自然语言文本片段与图像的相关性完成任务。[R14] 但本题类别名是 Class_0 至 Class_4，没有自然语言语义，所以 “a photo of Class_0” 基本没有信息。

8.2 prompt 设计流程

- 先为每类做 50 张 montage，人工观察类别内共性，不要凭空编。
- 描述属性包括：大小、形状、边缘、颜色深浅、内部纹理、背景、对比度、模糊程度。
- 每类写 5-10 个英文 prompt；对同一类 prompt 的文本 embedding 求平均。
- prompt 概率只作为弱先验，必须和 support cache/linear probe 融合。

```
prompts = {
  'Class_0': [
    'a microscopy image of a compact purple cell nucleus',
    'a small histology crop containing a dark round stained nucleus',
    'a low resolution microscope image of a purple nucleus with sharp boundary'
  ],
  # Class_1 ~ Class_4: 观察 montage 后分别写，不要复制同一模板
}
```

8.3 Few-shot cache 更重要

CLIP/OpenCLIP/BioMedCLIP 分支最终建议这样用： $p_{clip} = 0.2 * p_{text_prompt} + 0.5 * p_{support_cache} + 0.3 * p_{linear_probe}$ 。也就是说，prompt 只提供一点语义先验，真正分类靠 250 张 support set 的图像 embedding。

8.4 RAG/LLM 的边界

截图中鼓励 “大语言模型 + RAG 的 few-shot 推理”。对本题，最稳的 RAG 实现不是让 LLM 直接看图决定类别，而是用视觉 embedding 检索 top-k 训练样本，把 “相似样本类别、相似度、图像统计特征” 交给 LLM 生成解释。最终 label 仍由数值模型输出。

- 可做：FAISS/NearestNeighbors 检索 top-k 支持样本，用于 cache logits、错误分析和报告解释。
- 谨慎做：把图像描述交给 LLM 让其投票；小图细粒度差异不可靠，且现场耗时大。
- 不要做：引入外部带标签图像样本作为检索库；这违反作业约束。

9. TTA、伪标签、label propagation 与现场 test-time adaptation

9.1 TTA

TTA 是低风险高收益手段。对细胞核图像，方向通常不是语义标签，因此 D4 变换适合做稳定推理。

TTA 档位	包含变换	适用场景
fast	identity + hflip + vflip	现场时间紧或模型很多。
safe	identity + hflip + vflip + rot90 + rot180 + rot270	推荐默认档。
full	safe + transpose/anti-transpose + 轻亮度/对比度 TTA	模型少或时间充足时使用。

```
# TTA 融合方式
# 对每个 view 提取 feature 或概率，先对每个 view 的 feature L2 normalize，
# 再平均；或每个 view 率后求均。
z = mean([normalize(encoder(t(img))) for t in tta_views])
z = normalize(z)
prob = mean([clf.predict_proba(z_view) for z_view in z_views])
```

9.2 现场无标签测试集适配

老师现场提供测试集。如果规则允许使用无标签测试图像做 test-time adaptation，可以开启 label propagation 或一轮高置信伪标签；如果老师明确禁止，就关闭。必须在代码里做成开关。

方法	步骤	安全设置
----	----	------

Label propagation	训练集 250 张为 labeled anchors，测试集为 unlabeled nodes；在 best embedding 上建 kNN graph，传播概率。	最终 $p = 0.75 * p_{supervised} + 0.25 * p_{lp}$ ；权重可用 OOF 模拟调。
高置信伪标签	ensemble 预测测试集；选 $p_{max} > 0.95$ 且 top1-top2 margin > 0.15 的样本；加入轻量头重训。	每类 cap；sample_weight=0.1-0.3；只迭代 1 次。
测试分布校正	只做非常轻的 class bias 或温度校准。	不要强制预测分布均匀，因为测试集明确不均衡。

现场规则优先

transductive adaptation 只有在课程规则允许使用无标签测试图片时才能开启。默认提交脚本建议提供 --mode safe 和 --mode full，safe 不做伪标签，full 在允许时启用。

10. OOF 融合、校准、类别偏置与模型选择

最终分数通常由融合决定。多模型不要靠主观权重，必须基于 out-of-fold 概率学习。

10.1 保存 OOF 概率

- 每个分支保存 oof_probs: [250,5]，test_probs: [N_test,5]。
- 同一训练样本的 OOF 概率必须来自未见过该样本的 fold。
- 保存 y_true、fold_id、model_name、input_variant、classifier_name，方便复现。

10.2 融合搜索

对每个分支概率先做温度缩放，再加权平均，最后可加 class bias。目标函数为 $0.5 * \text{macro-F1} + 0.5 * \text{balanced accuracy}$ 。

```
def fuse(probs_list, weights, temps=None, bias=None, eps=1e-9):
    fused = 0
    for i, p in enumerate(probs_list):
        if temps is not None:
            # 简化：概率转 log 后除温度，再 softmax
            logits = np.log(np.clip(p, eps, 1)) / temps[i]
            p = softmax(logits, axis=1)
        fused += weights[i] * p
    logits = np.log(np.clip(fused, eps, 1))
    if bias is not None:
        logits = logits + bias[None, :]
    return softmax(logits, axis=1)
```

参数	搜索范围	备注
weights	非负, sum=1; 可用 Optuna/随机搜索/网格搜索	先在 top 5-10 分支搜索，避免维度过大。
temperature	0.5-3.0	校准过度自信或过度平滑的分支。
class bias	每类 -0.5 到 0.5 小范围	只根据 OOF 调；过大容易损 precision。
分支筛选	保留单模型强或错误互补的分支	OOF 差且和强模型高度相关的分支删除。

10.3 融合后的必要诊断

- 查看每类 recall/F1：balanced accuracy 低通常说明某类 recall 崩了。
- 查看每类 precision：macro-F1 低但 balanced accuracy 高，可能是某类报太多。
- 查看 confusion matrix：找最混淆的类别对，为 prompt、class bias、augmentation 和误差分析提供依据。
- 低置信样本 top 20：人工观察是否模糊、背景异常、类别边界不清或标注可能噪声。

11. 双 GPU 现场运行流程与离线准备

11.1 赛前离线准备

- 下载并缓存所有模型权重：DINOv2/DINOv3/timm/OpenCLIP/BioMedCLIP/Phikon-v2/Cell-DINO。
- 把 HuggingFace cache、OpenCLIP cache、timm cache 放到固定目录，设置 HF_HOME、TORCH_HOME。
- 测试无网络运行：TRANSFORMERS_OFFLINE=1、HF_HUB_OFFLINE=1。

- 保存最终 fusion_weights.json、temperatures.json、class_bias.json。
- 准备 requirements.txt 或 environment.yml；锁定 torch、transformers、timm、open_clip_torch、scikit-learn、peft 版本。
- 写好 fail-safe：任何单个模型加载失败，记录 warning 并跳过，不影响输出 submission.csv。

```
export HF_HOME=/path/to/hf_cache
export TORCH_HOME=/path/to/torch_cache
export TRANSFORMERS_OFFLINE=1
export HF_HUB_OFFLINE=1

python scripts/check_env.py
python scripts/extract_features.py --split train --mode safe
python scripts/cv_train_heads.py --config configs/final.yaml
python scripts/infer.py --test_dir /path/to/test --mode safe
```

11.2 GPU 分工

GPU	负责分支	原因
RTX Pro 6000	大模型特征抽取：DINOv3-L/H、DINOv2-g、Phikon-v2	显存充足，适合 batch 大一些跑大 backbone。
RTX 5090	OpenCLIP/BioMedCLIP/ConvNeXt/传统特征/分类头训练	并行提特征和跑轻量模型，缩短现场时间。
CPU	LogReg/Ridge/SVM、kNN、融合、CSV 检查	这些步骤计算量小，但 I/O 和内存要稳定。

11.3 现场三档模式

模式	内容	什么时候用
fast	2-3 个最稳 backbone + identity/flip TTA + 预训练 heads + 融合	时间非常紧或环境不稳定。
safe	fast + D4 TTA + 医学分支 + cache/kNN + OOF 融合	推荐默认提交模式。
full	safe + LoRA 分支 + label propagation/伪标签（若允许）+ 多输入版本	时间充足且现场规则允许。

11.4 输出前检查

```
import pandas as pd
sub = pd.read_csv('submission.csv')
assert list(sub.columns) == ['filename', 'label']
assert sub['filename'].is_unique
assert sub['label'].isin([f'Class_{i}' for i in range(5)]).all()
print(sub.head())
print(sub['label'].value_counts())
```

12. 代码结构、命令行与关键伪代码

12.1 推荐仓库结构

```
project/
  configs/
    final.yaml
    models.yaml
    fusion_weights.json
  data/
    train_few_shot/
    test/                # 现场复制进来
  features/
    train_dinov2_l_rgb.npy
    test_dinov2_l_rgb.npy
  oof_probs/
  test_probs/
  checkpoints/
    lora_dinov2_fold0.pt
```

```
reports/
  eda/
    confusion_matrices/
scripts/
  eda.py
  build_folds.py
  extract_features.py
  train_heads.py
  tune_fusion.py
  train_lora.py
  infer.py
  check_submission.py
submission.csv
README.md
```

12.2 特征抽取接口

```
# 所有 backbone 统一输出 L2 normalized embedding
class FeatureExtractor:
    def __init__(self, name, device):
        self.name = name
        self.model, self.preprocess = load_model_and_preprocess(name, device)

    @torch.inference_mode()
    def encode_batch(self, pil_images):
        x = torch.stack([self.preprocess(im) for im in pil_images]).to(self.device)
        feat = self.model_forward_feature(x)      # [B, d]
        feat = torch.nn.functional.normalize(feat, dim=1)
        return feat.cpu().numpy()
```

12.3 训练和推理命令

```
# 赛前训练
python scripts/eda.py --train_dir data/train_few_shot
python scripts/build_folds.py --n_splits 5 --n_repeats 10 --seed 42
python scripts/extract_features.py --split train --models dinov2_l,phikon,biomedclip --tta train
python scripts/train_heads.py --config configs/final.yaml
python scripts/tune_fusion.py --metric macro_f1_bacc

# 现场推理
python scripts/extract_features.py --split test --test_dir data/test --models final --mode safe
python scripts/infer.py --test_dir data/test --mode safe --out submission.csv
python scripts/check_submission.py --submission submission.csv

# 规则允许无标签适配时
python scripts/infer.py --test_dir data/test --mode full --use_transductive 1 --out
submission.csv
```

12.4 配置文件核心字段

```
seed: 42
classes: [Class_0, Class_1, Class_2, Class_3, Class_4]
cv:
  n_splits: 5
  n_repeats: 10
models:
  - name: dinov2_vitl14_reg
    input_variants: [rgb, gray3]
    tta: d4
    heads: [logreg, ridge, cache, knn]
  - name: phikon_v2
    input_variants: [rgb, contrast]
    tta: d4
    heads: [logreg, cache]
heads:
  logreg_C: [0.01, 0.03, 0.1, 0.3, 1, 3, 10, 30, 100]
  cache_beta: [5, 10, 20, 40, 80]
fusion:
  objective: 0.5*macro_f1 + 0.5*balanced_accuracy
```

```
tune_temperature: true
tune_class_bias: true
```

13. 实验报告写法、消融表格与误差分析

报告不是只写“我用了某模型”，而是要证明：为什么这条技术路线适合 50-shot；每个模块是否真的有效；模型在哪些类别失败；大模型来源、许可证和成本是否合规。

13.1 报告结构

- 任务理解：5 类、每类 50 张、32×32 RGB、测试集不均衡、指标为 macro-F1 与 balanced accuracy。
- 方法动机：小样本从零训练容易过拟合；因此采用预训练 backbone + linear/few-shot/head fusion。
- 数据与验证：EDA、重复分层交叉验证、防泄漏策略。
- 模型方案：通用视觉分支、医学分支、CLIP few-shot 分支、传统特征分支、LoRA 分支。
- 关键实验：各 backbone、各分类头、TTA、多输入版本、cache、LoRA、伪标签、融合权重。
- 误差分析：confusion matrix、每类 precision/recall/F1、最易混淆类别、失败图例、最近邻解释。
- 大模型使用情况：模型来源、参数量、许可证、输入尺寸、推理时间、是否使用外部标签数据。
- 失败尝试：从零 CNN、强 crop、纯 zero-shot prompt、过强 MixUp/CutMix 等。

13.2 消融表模板

实验 ID	Backbone/特征	分类头	TTA	macro-F1	bAcc	结论
A0	HOG+LBP+Color	LinearSVC	否			传统 baseline
A1	DINOv2-L RGB	LogReg	否			主 baseline
A2	DINOv2-L RGB	LogReg+cache	D4			检索增益
A3	Phikon-v2/ BioMedCLIP	LogReg+cache	D4			医学分支
A4	OpenCLIP/SigLIP	prompt+cache	D4			CLIP few-shot
A5	Top 5 ensemble	OOF weighted	D4			融合
A6	Top ensemble + LoRA	OOF weighted	D4			PEFT 增益
A7	Full + transductive	OOF weighted	full			仅在规则允许时

13.3 误差分析怎么写

- 每类召回低：展示该类被错分到哪些类；查最近邻是否图像形态相似。
- 某类 precision 低：说明模型过度预测该类，检查 class bias 或融合权重。
- 最混淆类别对：放 5 张真实 A 预测 B 和 5 张真实 B 预测 A 的图，观察共同视觉属性。
- 低置信样本：可能是模糊、边界不清、染色弱、背景强噪声，适合作为失败例。
- 不同 backbone 互补：列出某模型错但另一模型对的样本，说明融合动机。

13.4 模型使用记录模板

模型	来源	参数量	输入尺寸	许可证	本项目用途	推理成本
DINOv2 ViT-L/G	facebookresearch/dinov2	约 300M / 1100M	224/518 等，按实现	官方仓库/权重条款	frozen feature + heads	记录 batch size 与每张 ms
DINOv3 ViT/ConvNeXt	facebookresearch/dinov3 / HF	按所选模型	按模型 processor	DINOv3 License	frozen feature + heads	记录
Phikon-v2	owkin/phikon-v2	约 0.3B	224×224	Owkin non-commercial	histology feature	记录
BioMedCLIP	microsoft/BiomedCLIP...	ViT-B + PubMedBERT	224/256，按 preprocess	MIT	image encoder + prompt/cache	记录
OpenCLIP/SigLIP	mlfoundations/open_clip 或 HF	按模型	224-336	按权重	image encoder + cache	记录

14. 风险控制、最终清单与执行顺序

14.1 最大风险

风险	表现	处理
过拟合	训练集极高，OOF 波动大；LoRA 单 fold 特别好但重复后不稳。	冻结 backbone；重复 CV；降低 LoRA 权重；加正则。
CSV 格式错误	列名、label 字符串或文件顺序错误。	check_submission.py 强制断言；输出前打印 value_counts。
现场无网络	模型权重无法下载。	提前缓存并做 offline 测试。
某 backbone 加载失败	版本不兼容或许可证未授权。	try/except 跳过；保留 fast/safe fallback。
强增强破坏语义	验证集下降，低置信样本变多。	只保留 OOF 有收益的增强。
伪标签错误放大	某类预测过多，macro-F1 降。	高阈值、per-class cap、sample_weight 低、只一轮。
不合规外部标签	使用外部带标签图像数据训练/验证。	严格禁止；只用公开预训练权重。

14.2 最终执行顺序

- 先跑 EDA 和传统特征 baseline，确保数据和评估代码正确。
- 跑 DINOv2-L/G frozen feature + LogisticRegression + cache，建立主 baseline。
- 加入 Phikon-v2、BioMedCLIP、Cell-DINO 或其他医学/细胞分支。
- 加入 DINOv3/ConvNeXt/EVA/OpenCLIP/SigLIP 互补分支。
- 对每个强分支做 D4 TTA、多输入版本和 cache/kNN。
- 保存全部 OOF 概率，搜索融合权重、温度、class bias。
- 只对 top 2-3 分支做 LoRA/Adapter，比较 OOF 稳定性。
- 写 infer.py 的 fast/safe/full 三档，完成无网络、单分支失败、CSV 检查测试。
- 现场拿到测试集后先跑 safe；如果时间和规则允许，再跑 full。
- 提交前检查 submission.csv 的列名、文件名唯一性、label 合法性和预测分布。

最终推荐提交版本

默认使用 safe 模式：DINOv2/DINOv3 + Phikon-v2/BioMedCLIP + OpenCLIP/SigLIP + 传统特征，全部 frozen embedding，LogReg/Ridge/cache/kNN，D4 TTA，OOF 学融合权重。full 模式再加入 LoRA 和 transductive adaptation。

附录 A. 超参数搜索表

模块	超参数	搜索范围	建议默认
LogReg	C	0.01,0.03,0.1,0.3,1,3,10,30,100	1 或 OOF 最优
Ridge	alpha	0.1,0.3,1,3,10,30,100	10
LinearSVC	C	0.01,0.03,0.1,0.3,1,3,10	0.3
kNN	k	1,3,5,7,11,15	5 或 OOF 最优
Cache	beta	5,10,20,40,80	20
Cache	topk	None, 10, 20, 50	20
TTA	views	fast/safe/full	safe
Input	variant	rgb, gray3, contrast, denoise	rgb + gray3
LoRA	rank	4,8,16	8
LoRA	lr	1e-5,3e-5,1e-4	3e-5
LoRA	label smoothing	0,0.03,0.05,0.1	0.05
Fusion	temperature	0.5-3.0	OOF 调
Fusion	class bias	-0.5 到 0.5	OOF 调，小范围
Pseudo-label	threshold	0.90,0.95,0.98 + margin	0.95 + margin 0.15

附录 B. 参考资料与许可证记录模板

以下资料用于方案设计和报告撰写。实际提交报告时，请把最终使用的模型逐一列出来源、许可证、参数量和推理成本。

编号	资料	URL / 说明
[C0]	课程项目文件	项目具体内容.md（用户上传）：任务、数据、提交格式、允许/禁止事项和报告要求。

[R1]	scikit-learn balanced_accuracy_score	https://scikit-learn.org/stable/modules/generated/sklearn.metrics.balanced_accuracy_score.html
[R2]	scikit-learn f1_score	https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html
[R3]	DINOv2 官方 GitHub	https://github.com/facebookresearch/dinov2
[R4]	DINOv3 官方 GitHub	https://github.com/facebookresearch/dinov3
[R5]	DINOv3 Model Card	https://github.com/facebookresearch/dinov3/blob/main/MODEL_CARD.md
[R6]	timm Feature Extraction 文档	https://huggingface.co/docs/timm/en/feature_extraction
[R7]	Phikon-v2 HuggingFace Model Card	https://huggingface.co/owkin/phikon-v2
[R8]	BioMedCLIP HuggingFace Model Card	https://huggingface.co/microsoft/BiomedCLIP-PubMedBERT_256-vit_base_patch16_224
[R9]	Cell-DINO, PLOS Computational Biology	https://journals.plos.org/ploscompbiol/article?id=10.1371/journal.pcbi.1013828
[R10]	OpenCLIP 官方 GitHub	https://github.com/mlfoundations/open_clip
[R11]	Tip-Adapter 官方 GitHub / ECCV 2022	https://github.com/gaopengcuhk/Tip-Adapter
[R12]	DINOv2 模型参数与 linear/kNN 表格	https://github.com/facebookresearch/dinov2
[R13]	HuggingFace PEFT LoRA 文档	https://huggingface.co/docs/peft/en/developer_guides/lora
[R14]	OpenAI CLIP 官方 GitHub	https://github.com/openai/CLIP
[R15]	UNI/CONCH 可选病理模型信息	https://huggingface.co/MahmoodLab/UNI ; https://huggingface.co/MahmoodLab/CONCH

许可证记录模板

模型	权重来源	许可证	是否 gated	是否用于训练	是否商用限制	备注
DINOv2				frozen / LoRA		
DINOv3				frozen / LoRA		
Phikon-v2		Owkin non-commercial		frozen / LoRA	是	
BioMedCLIP		MIT		frozen		
OpenCLIP/SigLIP				frozen		
Cell-DINO				frozen		

最后检查

在现场提交前，先用 safe 模式生成 submission.csv；如果 full 模式输出与 safe 模式差异巨大，优先信任 OOF 验证更稳定的版本。不要因为测试集预测分布看起来“不均匀”就手动改标签，测试集本身被说明是不均衡的。